

Reti di Calcolatori

Codifica del segnale vocale

Marco Cagnazzo



Il segnale vocale (parlato)

Il segnale vocale non può essere considerato come stazionario, ma piuttosto **localmente stazionario** su durate intorno ai 20 ms

Stazionarietà durante la pronuncia di un fonema

Suoni *vocali*

- Segnali *pseudo periodici* come le vocali ed alcune consonanti come "s", "f"


Suoni *non vocali*

- La maggior parte delle consonanti


Altri suoni

- Transizioni tra fonemi



Esempio suono *voiced*



pitch: 178Hz



Esempio suono *unvoiced*



Codifica del segnale vocale

Ci sono tre famiglie di codificatori per il segnale vocale:

Codificatori a forme d'onda

- Rappresentano il segnale, trascurando la sua semantica
- Nessuna compressione: formato PCM
- Bassa complessità, alta qualità del parlato, bitrate molto elevato

Codificatori vocali (Vocoder)

- Non cercano di preservare la forma d'onda del segnale vocale, ma modellano il **modo** in cui viene esso prodotto
- I parametri del modello sono stimati dal segnale (tipicamente usando la cosiddetta codifica predittiva lineare - LPC)
- I parametri sono trasmessi al ricevitore che li usa per sintetizzare la voce
- Bitrate molto bassi (2,4 kbps o anche inferiori), ma la qualità è generalmente molto bassa e non naturale.

Codificatori ibridi

- Si usano tecniche di vocoding per ricavare alcuni dei parametri del segnale + codifica della forma d'onda per rappresentare il residuo tra il parlato originale e quello sintetizzato

G.711: ITU- T Recommendation G.711

- Formato PCM non compresso
- Campionamento a 8 kHz
- Si usa una quantizzazione non uniforme adattata alle statistiche dei campioni
- Come visto prima, ha un tasso di **64 kbps**

G.729: Conjugate Structure-Algebraic Code Excited Linear Prediction (ACELP)

- Codificatore ibrido
- 8kHz sampling rate
- 15 ms di ritardo per il trattamento di un blocco di campioni
- Si raggiungono tassi intorno agli **8 kbps**

GSM (Full/Half/Enhanced/Adaptive Rate)

- Ibrido con LPC. Nella variante full-rate il tasso è di 13 kbps

AMR-WB (G.722.2)

- Lo standard per il "HD Voice" nelle reti mobili (LTE/5G). Campionamento a 16 kHz (Wideband) per una qualità naturale.

Opus (RFC 6716)

- Il codec moderno "universale". Ibrido, bitrate adattativo (6-510 kbps) e banda da 8 a 48 kHz. Usato da WhatsApp, Zoom e YouTube.

Esempio didattico: codifica LPC10

Vocoder di base (validità unicamente pedagogica)

Segnale d'ingresso campionato a 8kHz

I dati di ingresso vengono suddivisi in **finestre** di 20 ms, cioè in blocchi di $20 \cdot 10^{-3} \times 8 \cdot 10^3 = 160$ campioni

Idea: per ogni finestra, modelliamo il segnale vocale e inviamo i **parametri del modello**, non i campioni

Tali parametri saranno usati dal ricevitore per sintetizzare localmente il segnale vocale

Il modello si basa sulla **predizione lineare** emulando il tratto vocale umano

LPC10: linear prediction coding – predizione lineare basata sui 10 campioni precedenti

L'obiettivo è quello di produrre una **predizione** del campione corrente $x(n)$ usando una combinazione lineare dei 10 campioni precedenti

$$x_p(n) = \sum_{k=1}^{10} a_k x(n - k)$$


I coefficienti a_k vengono trovati minimizzando il valore quadratico medio dell'errore di predizione $y(n)$:

$$y(n) = x(n) - x_p(n) = x(n) - a_1 x(n - 1) - a_2 x(n - 2) - \dots - a_{10} x(n - 10)$$

L'errore di predizione y è quindi un *filtraggio a media mobile* del segnale vocale.

Tale filtro è **invertibile**: noto y è possibile ricostruire x tramite equazioni alle differenze (filtro autoregressivo)


Schema di codifica: il blocco LPC determina i coefficienti del filtro; il blocco $A(z)$ calcola l'errore di predizione. I coefficienti del filtro e l'errore di predizione sono quantizzati (perdita d'informazione) e trasmessi



Bisogna quindi trasmettere al ricevitore il residuo ed il filtro usato. Entrambe le informazioni vengono quantizzate per ridurre il bit-rate

Tuttavia, se la predizione è accurata, il residuo y diventa praticamente rumore. Consideriamo 2 casi:

1. rumore bianco (spettro piatto)
2. con una frequenza predominante, detta *pitch*)



Allora non c'è bisogno di trasmettere y , ma solo i suoi parametri (bianco / non bianco, potenza ed eventualmente pitch. Bisogna poi trasmettere anche i coefficienti del filtro, a

Notiamo che è facile determinare se il residuo è bianco oppure ha una frequenza predominante (si usa uno strumento detto *stima dell'autocorrelazione*)

Il decodificatore genera l'opportuno segnale di rumore ed userà i coefficienti del filtro per recuperare x

LPC10: suoni vocali e non vocali


Il residuo y è rappresentato come segue

Se il suono non è vocale, utilizziamo il **rumore bianco**

Se il suono è vocale, utilizziamo **un treno di impulsi periodici**

I parametri del treno d'impulsi (potenza e pitch, la fase non serve perché il rumore di fase è inaudibile) possono essere facilmente stimati dall'autocorrelazione

$$\hat{y}(n) = \alpha \sum_{m \in \mathbb{Z}} \delta(n - mT_0 + \phi)$$



Tasso di codifica: ogni 20 ms bisogna trasmettere
36 bits per i 10 coefficienti del filtro
1 bit per distinguere i suoni vocali/non vocali

- Nel caso di suoni vocali si trasmette la potenza (6 bits) e il pitch (periodo) (7 bits)
- Per suoni non vocali si trasmette solo la potenza (6 bits)

$$R_{\text{voiced}} = \frac{36+1+6+7}{20 \cdot 10^{-3}} = 2500 \text{ bps}$$

$$R_{\text{unvoiced}} = \frac{36+1+6}{20 \cdot 10^{-3}} = 2150 \text{ bps}$$

$$R_{\text{average}} = 2400 \text{ bps}$$

Esempio

Frase

e

t

Originale

Ricostruito




L'Effetto "Sussurrato" nel Vocoder LPC-10

- **Decisione Binaria V/UV:** Il modello impone una scelta esclusiva tra treno d'impulsi e rumore bianco, non ammettendo stati intermedi per singolo frame.
- **Errori di Classificazione:** Se un segmento sonoro (Voiced) viene identificato erroneamente come sordo, la struttura armonica scompare a favore dell'eccitazione stocastica.
- **Assenza di Eccitazione Mista:** Molti fonemi reali combinano vibrazione glottidale e turbolenza; l'LPC-10 elimina la componente periodica rendendo il suono puramente soffioso.
- **Semplificazione del Residuo:** L'uso di rumore bianco sintetico ignora la pendenza spettrale e la coerenza di fase del segnale originale, producendo un timbro artificiale.

Advanced voice encoders: ACELP

- La codifica LPC è troppo semplice, ma fornisce una valida base
- I codificatori più avanzati usano
 - **Modelli più sofisticati per il residuo y** : tipicamente si usa un dizionario piuttosto ampio di modelli
 - **Codifica ad anello chiuso**: I parametri vengono scelti in modo da minimizzare l'errore di codifica
 - Tale errore è ponderato secondo il fenomeno del mascheramento



Latenza: il ritardo di codifica contribuisce al ritardo complessivo del servizio

- Il ritardo di codifica può essere **algoritmico** (buffering del parlato per l'analisi o look-ahead) e **computazionale** (tempo di elaborazione)

Resilienza: le connessioni mobili soffrono molto di errori casuali e a burst → Il meccanismo di correzione degli errori (FEC) è fondamentale

FEC richiede tempo (elaborazione e memorizzazione) e bit-rate aggiuntivo

La quantità di bit-rate aggiuntivo dipende dai requisiti di rilevazione e correzione degli errori

<https://core.ac.uk/download/pdf/228199007.pdf>

Soppressione del silenzio: statisticamente, il 50% di una conversazione è costituito da silenzio

Le tecniche di soppressione del silenzio possono far risparmiare molta banda
Necessità di un rilevatore di attività vocale (VAD) per distinguere la voce dal rumore di fondo

Il VAD può causare un clipping del parlato e un'improvvisa soppressione del rumore con degrado della qualità

<https://core.ac.uk/download/pdf/228199007.pdf>

AMR-WB (G.722.2) – L'era dell'HD Voice

Adaptive Multi-Rate Wideband, lo standard de facto per la telefonia moderna su reti 4G (VoLTE) e 5G.

Specifiche Tecniche:

- Frequenza di campionamento: 16 kHz (il doppio rispetto ai sistemi tradizionali)
- Banda Audio: Estesa a 50 Hz – 7 kHz (Wideband).
- Bitrate Adattivo: 9 diversi tassi da 6.6 a 23.85 kbps, selezionati dinamicamente in base alla congestione della rete.
- Perché "Adaptive"?: Il sistema può sacrificare bit di codifica sorgente per aumentare la protezione del canale senza interrompere la comunicazione se il segnale radio peggiora

Il vantaggio della Wideband (Analisi Spettrale)

Limiti del Passato (Area Rossa):

La telefonia classica taglia le alte frequenze. Si perde la brillantezza e la distinzione tra fonemi simili (es. "f" e "s").

L'estensione AMR-WB (Area Blu/Nera):


Alte frequenze: Cattura le armoniche superiori che conferiscono nitidezza e permettono di riconoscere meglio l'identità del parlatore.

Struttura: Le armoniche vengono posizionate come multipli della frequenza fondamentale (Pitch) estratta in banda base.

Ampiezza: Non viene trasmessa. Il ricevitore la stima basandosi sull'energia della banda inferiore e sulla pendenza dell'involuppo LPC

Basse frequenze: Estende la risposta verso il basso abbassando la frequenza di taglio del filtro passa-banda: ciò elimina l'effetto "metallico" con un aumento del bit-rate contenuto

Risultato: Maggiore intellegibilità e riduzione drastica dell'affaticamento cognitivo durante le chiamate lunghe.



Opus (RFC 6716) – Il Codec "Universale"

Un unico standard per voce, musica e bassissima latenza

Progettato da Xiph.Org e standardizzato da IETF per sostituire tutti i codec precedenti nel mondo Internet

Perché è "Universale"?

Flessibilità: Gestisce bitrate da 6 kbps a 510 kbps

Banda: Supporta dal Narrowband (8 kHz) al Fullband (48 kHz - Hi-Fi)

Latenza: Ottimizzato per la comunicazione in tempo reale, con un ritardo algoritmico tipico di soli 26.5 ms, fondamentale per l'interattività

Status: È un software libero, royalty-free e open-source, a differenza degli standard G.7xx.

Come gestire sia la voce che la musica

- **Motore SILK (Voce)**

- Basato sulla predizione lineare (LPC) che abbiamo studiato
- Ideale per il parlato a basso bitrate, dove il modello del tratto vocale è molto efficiente

- **Motore CELT**

- Non usa modelli biologici (tratto vocale), ma codifica direttamente la forma d'onda tramite trasformate simili a quella di Fourier: si codificano solo le frequenze che “l'orecchio sente”
- Si attiva quando il bitrate aumenta o quando il segnale non è voce (es. musica, rumore ambientale)

- **Modalità Ibrida:** Opus può far lavorare i due motori contemporaneamente per coprire diverse parti dello spettro audio

WebRTC: È il codec obbligatorio per le chiamate via browser (Google Meet, Zoom, Teams)

App di Messaggistica: WhatsApp, Telegram e Signal usano Opus per tutti i messaggi vocali e le chiamate VoIP

Gaming: Discord utilizza esclusivamente Opus per garantire che la voce dei giocatori sia cristallina e senza ritardi durante i match

Streaming: Molti servizi (come YouTube) usano Opus per la traccia audio dei video perché è più efficiente dei vecchi formati a parità di qualità.

Conclusione

Le tecniche di codifica per la voce di tipo ibrido sono molto diffuse

Esse sfruttano sia l'approccio per analisi/sintesi basato su LPC, sia la codifica a forma d'onda del residuo

Permettono di ottenere un'ottima qualità (intelligibilità) della voce a tassi relativamente bassi (ordine di grandezza dei 10kbps, da confrontare con i 64kbps del segnale non compresso)